UNIVERSIDAD DEL VALLE DE GUATEMALA

DATA SCIENCE - 10

Ing. Erick Marroquin



Laboratorio 9. Visualización estática

Ihan Marroquin - 23108

Diego Patzan - 23525

GUATEMALA, 18 de octubre del 2026

Repositorio:
Infografia:

Explicación de las decisiones de diseño

La infografía comunica cómo cambió el ingreso mensual de viajeros entre enero de 2009 y junio de 2026 y qué límites tienen los modelos entrenados antes de la recuperación. La conclusión central es que el flujo se recuperó del desplome de 2020, pero el pronóstico del Lab 1 quedó persistentemente por debajo de lo observado. Por eso proponemos decisiones operativas apoyadas en la estacionalidad y una actualización del modelo antes de usarlo para presupuestos.

1 Audiencia y recorrido de lectura

Nos dirigimos a una persona del INGUAT que planifica campañas, personal y capacidad. Tiene pocos minutos para leer y no necesita conocer la formulación estadística. Usamos un titular informativo, cifras grandes, gráficos con unidades y recomendaciones vinculadas a evidencia. Los términos técnicos que no caben en el lienzo se definen en este documento.

Bloque del enunciado	Representación final y propósito
Titular y cifras	Titular sobre recuperación y pronóstico; cuatro indicadores dan escala al problema.
Panorama histórico	Línea mensual con eventos de contexto y banda del período usado para medir la caída.
Estacionalidad vías y mercados	Barras por mes, rankings horizontales y matriz de seis series.
Modelos y pronóstico	Tabla de ocho algoritmos sobre el mismo conjunto de prueba y predicción con intervalo del 95%.
Hallazgos y recomendaciones	Tres acciones concretas para campañas, segmentación y actualización predictiva.

El recorrido de arriba hacia abajo va del contexto a la decisión. El titular y los indicadores tienen mayor tamaño; la historia precede al calendario; la comparación estadística precede a las recomendaciones. Los cinco bloques del enunciado están presentes: el titular no lleva número y los otros cuatro se identifican del 01 al 04.

2 Alcance de los datos

Usamos la Base de Migración 2009-2026 INGUAT/IGM facilitada en el curso. Conservamos Turista y Excursionista, como en el Lab 1; excluimos Crucerista y Viajero para mantener el mismo alcance. Son registros agregados de ingresos de viajeros, no personas únicas. El período tiene 210 observaciones mensuales; 2026 solo incluye enero a junio. Las cifras no se presentan como una nueva publicación oficial de las instituciones.

La variable País cambia de nivel de detalle después de 2023, según la advertencia del análisis previo. Guatemala se conserva como categoría registrada en la base y no se interpreta automáticamente como turismo interno, nacionalidad ni mercado internacional independiente. Esta limitación impide convertir el ranking acumulado en una recomendación de inversión por país sin validación adicional.

3 Historia y estacionalidad

La línea es apropiada para observaciones mensuales ordenadas: conserva la secuencia, muestra crecimiento, caída y recuperación sin introducir agregaciones anuales engañosas. El eje inicia en cero. Las anotaciones de H1N1 y Volcán de Fuego ubican hechos que plantea el análisis previo; no constituyen pruebas de impacto o ausencia de impacto. Sustituimos la afirmación absoluta de las imágenes recibidas por una lectura descriptiva.

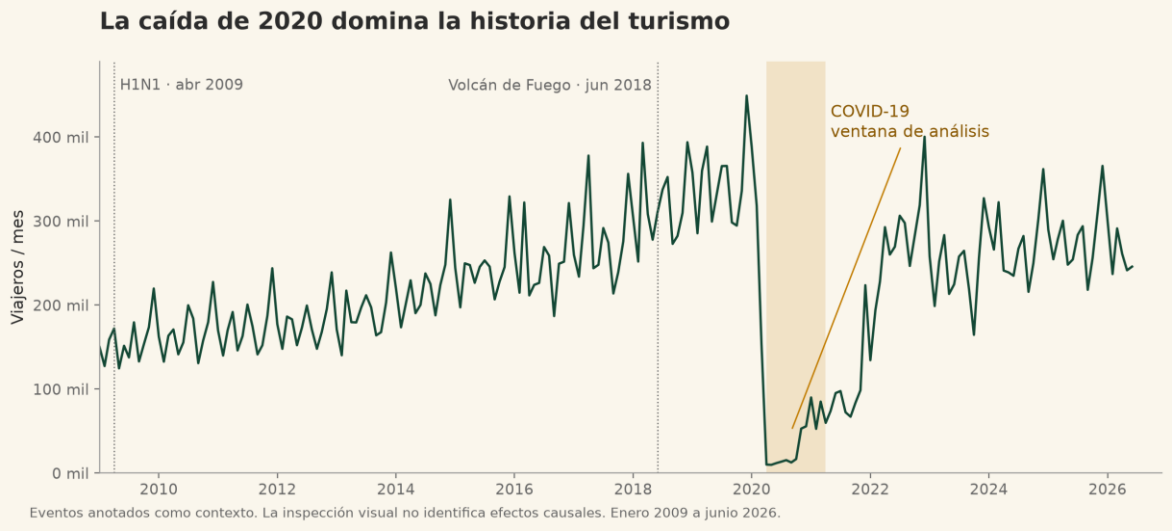


Figura 1. La banda abril 2020-marzo 2021 es una ventana de medición, no la duración completa de la pandemia.

Para el calendario calculamos 100 × (viajeros del mes / promedio mensual de su año - 1), y luego promediamos por mes del calendario dando el mismo peso a cada año. Excluimos 2020 y 2021 por la ruptura y 2026 porque está incompleto. Quedan 15 años completos: 2009-2019 y 2022-2025. Las barras parten de cero y separan valores positivos, negativos y diciembre mediante color y etiquetas numéricas.

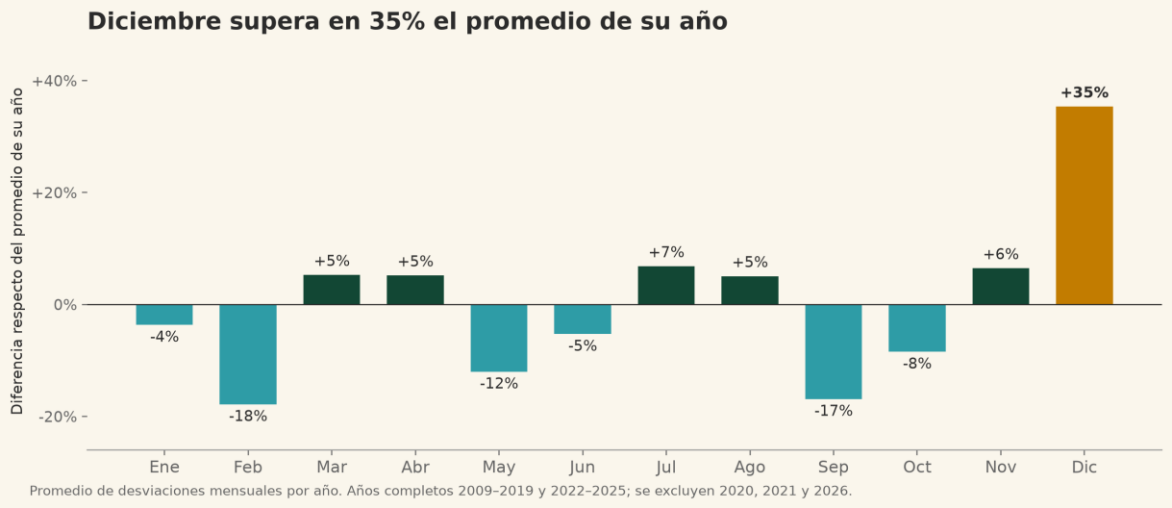


Figura 2. Diciembre está 35.34% sobre el promedio anual; febrero -17.83% y septiembre -16.89%. Valores del lienzo redondeados.

El patrón coincide con una mayor movilidad al cierre de año; la base no permite demostrar que aguinaldo o fiestas sean su causa. Tampoco atribuimos los pequeños aumentos de marzo, abril o julio a Semana Santa o Bono 14 sin identificar fechas y contrastes adicionales. La estacionalidad descriptiva de años completos y la fuerza STL de entrenamiento responden preguntas distintas y no deben confundirse.

4 Cifras vías mercados y comparación de series

Indicador	Cálculo y resultado
Promedio mensual	Suma de los 210 meses / 210 = 222,437.68; se muestra 222,438.
Máximo mensual	449,114.07 en diciembre de 2019; se muestra 449,114.
Caída en pandemia	1 - promedio abr 2020-mar 2021 / promedio ene-dic 2019 = 89.6958%; se muestra 89.7%.
La Aurora acumulado	18,989,984.61 en el período; se muestra 18.99 millones.

Los rankings usan barras horizontales con origen cero porque comparan categorías sin orden natural y nombres largos. La vía terrestre acumula 27.59 millones, la aérea 19.02 millones y la marítima 100,241 ingresos comparables. El volumen marítimo excluye Crucerista y por tanto no representa todo el turismo de cruceros. El Salvador, Guatemala y Estados Unidos son los tres mayores valores acumulados de País: 14.08, 13.87 y 6.97 millones, con las restricciones ya descritas.

Definiciones de las cuatro medidas

Estacionalidad: max(0, 1 - Var(residuo) / Var(estacional + residuo)) de una STL robusta sobre log(1+y), período 12, usando solo entrenamiento. Crecimiento: pendiente de una recta sobre log(1+y) entre enero de 2022 y junio de 2026; es una medida mensual en escala logarítmica, no un porcentaje directo. Volatilidad: desviación estándar poblacional de las primeras diferencias de log(1+y) de toda la serie. Caída: reducción del promedio abril 2020-marzo 2021 frente al promedio de 2019.

Serie	Fuerza STL	Pendiente	Volatilidad	Caída
América del Centro	0.004	-0.0014	0.301	89.8%
América del Norte	0.000	+0.0115	0.907	87.4%
Europa	0.075	+0.0082	0.741	94.1%
La Aurora	0.057	-0.0001	0.425	84.2%
Valle Nuevo	0.000	+0.0049	0.692	96.3%
San Cristóbal	0.255	+0.0116	0.580	95.1%

La tabla visual permite responder las cuatro preguntas sin combinar magnitudes incompatibles en un único índice. El ocre resalta el mayor valor dentro de regiones y dentro de fronteras. Entre regiones, Europa presenta mayor fuerza estacional y caída; América del Norte, mayor crecimiento y volatilidad. Entre fronteras, San Cristóbal presenta mayor estacionalidad y crecimiento; Valle Nuevo, mayor volatilidad y caída. En las seis series, los máximos globales son San Cristóbal para estacionalidad y crecimiento, América del Norte para volatilidad y Valle Nuevo para caída.

Recomendaciones derivadas de la evidencia

Primero, preparar capacidad para diciembre y probar campañas en febrero y septiembre con metas medibles de demanda. Segundo, segmentar las decisiones por región y frontera: las fuertes caídas históricas de Europa y Valle Nuevo justifican revisar su recuperación con datos actuales, antes de reasignar presupuesto. Tercero, reentrenar y validar por ventanas móviles

con datos recientes; el corte de entrenamiento en pandemia limita el pronóstico. Los resultados históricos orientan estas revisiones y no prueban por sí solos dónde invertir hoy.

5 Comparación de modelos

Conservamos la división temporal del Lab 1: enero 2009-marzo 2021 para entrenamiento (147 meses) y abril 2021-junio 2026 para prueba (63 meses). MAE es el promedio del error absoluto; RMSE penaliza con más fuerza los errores grandes. Ambos se expresan en viajeros y deben compararse entre algoritmos de la misma serie y horizonte. No se usan para concluir que una región es más predecible que otra con diferente volumen.

Modelo total mensual	MAE viajeros	RMSE viajeros
ARIMA(2,1,0)	156,261.29	170,915.02
ARIMA(0,1,2)	156,513.34	171,210.54
ARIMA(2,1,2)	165,701.09	180,457.50
Exponencial simple	165,372.54	180,598.23
Holt-Winters aditivo	172,351.72	184,529.72
Naive estacional	207,321.64	219,663.87
SARIMA(2,1,2)×$(1,0,1)_{12}$	210,905.81	225,573.47
Respaldo aditivo*	239,790.76	252,070.38

El ganador guardado del total es ARIMA(2,1,0), por menor RMSE, con MAE como segundo criterio de orden. Los valores de esta tabla se leen del CSV original del Lab 1. El modelo rotulado como respaldo aditivo usa una regresión Ridge con tendencia, cambios de pendiente y términos de Fourier; no es Prophet oficial. SARIMA y las variantes ARIMA se incluyen tal como fueron evaluadas. AIC y BIC no se usan para ordenar familias diferentes ni series diferentes; están disponibles en las tablas fuente.

Ganadores originales de las siete series

Serie	Modelo ganador	MAE	RMSE
Total mensual	ARIMA(2,1,0)	156,261	170,915
América del Centro	ARIMA(2,1,0)	105,942	117,900
América del Norte	ARIMA(2,1,0)	29,651	34,120
Europa	Exponencial simple	9,571	10,978
La Aurora	ARIMA(0,1,2)	35,684	40,874
Valle Nuevo	Holt-Winters aditivo	32,214	34,625
San Cristóbal	Exponencial simple	20,483	23,092

Ningún método gana en todas las series. El Lab 1 guardado elige ARIMA(2,1,0) para total, América del Centro y América del Norte; ARIMA(0,1,2) para La Aurora; exponencial simple para Europa y San Cristóbal; Holt-Winters aditivo para Valle Nuevo. Estas filas corrigen el avance, que utilizó candidatos y cifras de otra comparación. La versión entregada no mezcla esos resultados.

Alcance de esta elección

El conjunto de prueba se usa para comparar modelos y elegir el ganador histórico. Eso no equivale a una evaluación final independiente de un modelo ya elegido. Además, casi todo el horizonte de prueba pertenece a la recuperación y el entrenamiento termina en un nivel muy bajo. Antes de recomendar un pronóstico operativo corresponde validar por ventanas móviles y reservar una evaluación futura, en lugar de extrapolar esta tabla hasta diciembre de 2026.

6 Predicción e incertidumbre

Reajustamos únicamente el ganador del total con la especificación original: SARIMAX sobre log(1+y), orden (2,1,0), sin tendencia y sin imponer estacionariedad ni invertibilidad. El ajuste convergió. La validación reproduce MAE 156,261.29 y RMSE 170,915.02, con diferencias inferiores a 0.00001 viajeros frente al CSV conservado.

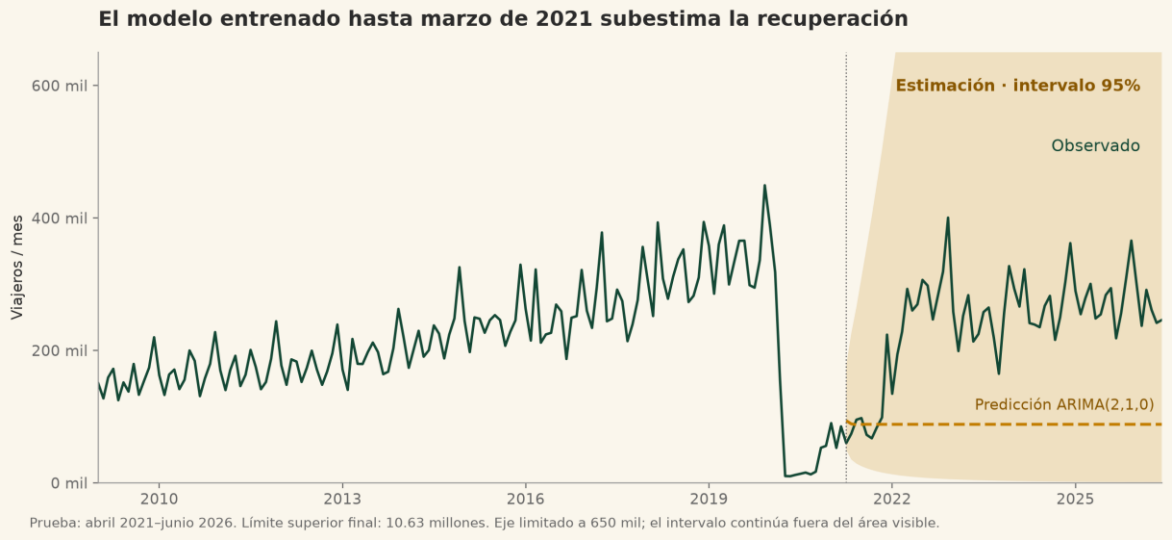


Figura 3. Serie observada, predicción del ganador del Lab 1 e intervalo del 95% rotulado Estimación. La banda excede el eje visible.

Los límites se calculan en escala logarítmica y se transforman con exp(x)-1, con piso cero. La curva puntual mantiene la convención del Lab 1: exp(media logarítmica)-1; corresponde a una mediana condicional, no a la media aritmética con ajuste de sesgo. El primer intervalo es aproximadamente [49,562, 177,069]; el límite superior final alcanza 10.63 millones.



Figura 4. Vista complementaria en escala logarítmica que muestra la amplitud completa del intervalo; no se usa para comparar alturas como proporciones lineales.

El intervalo es predictivo y condicionado a los supuestos del modelo; en el lienzo se conserva el rótulo 95% que pide el enunciado. Los 63 valores observados caen dentro de él, pero una cobertura de 100% con amplitud extrema no demuestra una buena predicción. El intervalo no incorpora explícitamente incertidumbre sobre cambios estructurales. El eje de la infografía se limita a 650 mil para leer la serie; una nota declara el recorte y el límite completo, que se muestra aquí. Todo el gráfico es retrospectivo sobre prueba, no una proyección posterior a junio de 2026.

7 Decisiones de diseño y teoría del color

Conservamos la dirección visual propuesta en el avance: una familia sans serif, fondo crema, línea histórica verde y un acento cálido para dirigir la atención. Verde y turquesa forman una relación cercana en el círculo cromático; el ocre introduce contraste de temperatura. Las asociaciones con naturaleza, agua y maíz son decisiones de diseño contextual y no propiedades estadísticas de los datos.

Color	Función semántica
Verde selva #124734	Serie observada, barras positivas y jerarquía visual.
Turquesa #2E9CA6	Desviaciones mensuales negativas; se acompañan de signo y etiqueta.
Ocre #C27C00	Pico de diciembre, banda histórica, ganador y predicción. El texto pequeño usa un tono más oscuro de la misma familia.
Crema #FAF6EC y gris #2B2B2B	Fondo neutro y texto principal, respectivamente.

El color no es el único canal: observación y predicción se diferencian con línea continua y discontinua; los valores negativos llevan signo; los ganadores están en negrita; las bandas están rotuladas. Evitamos afirmar accesibilidad completa para todos los tipos de daltonismo sin pruebas. El acento de texto se oscurece para mejorar el contraste sobre crema. Se evita depender del turquesa para leer cifras pequeñas.

Las barras parten de cero, se rotulan unidades y se eliminan 3D, sombras, fondos saturados y leyendas lejanas. El único recorte deliberado es el eje del intervalo predictivo y se declara

junto al gráfico. Las reglas de separación son discretas; los gráficos conservan espacio para ejes y etiquetas. Las tarjetas de indicadores se construyen con tipografía y espacio, sin cajas decorativas.

8 Correcciones frente a lo recibido

Elemento	Decisión verificable
Ganador del total	Se conserva ARIMA(2,1,0) del CSV del Lab 1. ARIMA(0,1,1) del script recibido es otro candidato y no reemplaza el análisis original.
Intervalo final	10.63 millones con el ganador original; 20.64 millones pertenecen al candidato del avance.
Estacionalidad	Se excluye 2026 incompleto además de 2020-2021. Enero queda -4%, febrero -18% y marzo +5% al redondear.
Eventos y fiestas	Se reemplazan afirmaciones causales por observaciones descriptivas y contexto.
Respaldo aditivo	Se identifica expresamente como respaldo del Lab 1 y no como Prophet oficial.

9 Formatos del documento y la infografía

El PNG tiene 3507 × 4960 píxeles, superior al mínimo 1200 × 2400. El enunciado mezcla dos tamaños de impresión distintos: A3 mide 297 × 420 mm y 11 × 17 pulgadas mide 279.4 × 431.8 mm. Se entregan dos PDF separados de una página, uno por cada tamaño, manteniendo el mismo contenido. El informe se entrega únicamente en PDF en la raíz del repositorio. La infografía completa ocupa una página independiente al final de este documento.

10 Reproducción y archivos de trabajo

El procesamiento es local. Los scripts de src generan tablas, gráficas, infografía e informe y verifican dimensiones, páginas y métricas. results/tables/auditoria.json registra versiones y SHA-256 de los insumos. Solo se redondea al presentar resultados.

Para reproducir los resultados en Windows con Python 3.12, ejecutar los siguientes comandos desde la raíz del repositorio. La generación del informe PDF utiliza Microsoft Word en Windows o LibreOffice en otros sistemas.

```
python -m venv .venv
.venv\Scripts\Activate.ps1
pip install -r requirements.txt
python src/analisis.py
python src/visualizacion.py
python src/documento.py
python src/verificar_entrega.py
```

El turismo se recupera pero el pronóstico quedó atrás

Una caída de 89.7% durante la pandemia cambió la serie. El reto es anticipar la recuperación.

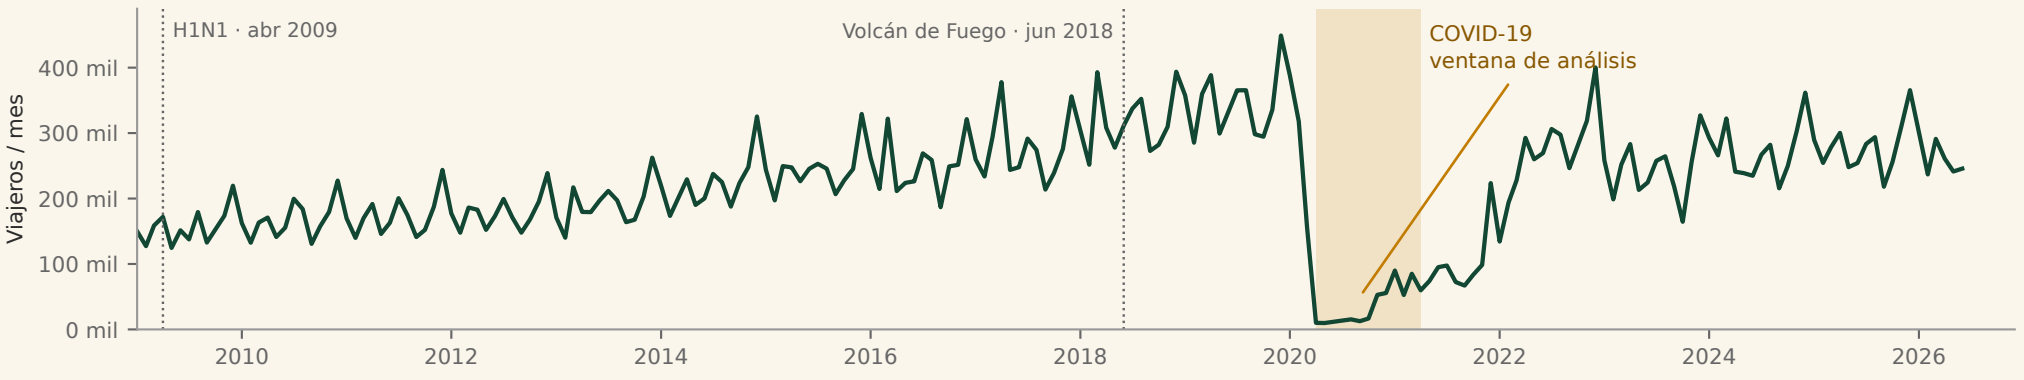
222,438
viajeros por mes
promedio del período

449,114
máximo mensual
diciembre de 2019

−89.7%
promedio abr 2020–mar 2021
frente al promedio de 2019

18.99 M
viajeros por La Aurora
acumulado del período

01 La pandemia marca el quiebre más visible

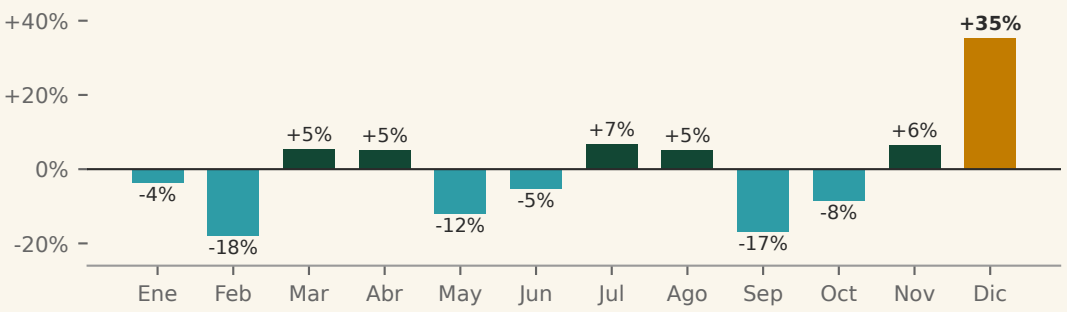


H1N1 y la erupción se señalan como contexto; no se atribuyen efectos causales por inspección visual.

La banda destaca abr 2020–mar 2021, la ventana usada para medir la caída. 2026 contiene seis meses.

02 Diciembre concentra el pico y la vía terrestre lidera

Diferencia mensual respecto del promedio de su año

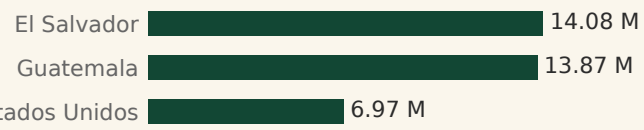


Años completos sin 2020 y 2021. Diciembre: +35%; febrero: −18%.

Vías · viajeros acumulados



Mercados registrados · top 3



País cambia de detalle después de 2023; Guatemala es una categoría de la base. No se interpreta como nacionalidad ni turismo interno.

Seis series del equipo · comparación dentro de regiones y dentro de fronteras

Serie	Estacionalidad[1]	Crecimiento[2]	Volatilidad[3]	Caída COVID
América del Centro	0.004	-0.0014	0.301	89.8%
América del Norte	0.000	**+0.0115**	**0.907**	87.4%
Europa	**0.075**	+0.0082	0.741	**94.1%**
La Aurora	0.057	-0.0001	0.425	84.2%
Valle Nuevo	0.000	+0.0049	**0.692**	**96.3%**
San Cristóbal	**0.255**	**+0.0116**	0.580	95.1%

[1] Fuerza STL en entrenamiento (0–1). [2] Pendiente mensual de log(1+y), ene 2022–jun 2026; no es un porcentaje.

[3] Desviación de cambios en log(1+y). Ocre: mayor valor en cada grupo. San Cristóbal lidera estacionalidad y crecimiento.

03 El mejor modelo histórico tampoco anticipó la recuperación

Total mensual · errores en viajeros · menor es mejor

Modelo	MAE	RMSE
ARIMA(2,1,0)	156,261	170,915
ARIMA(0,1,2)	156,513	171,211
ARIMA(2,1,2)	165,701	180,458
Exponencial simple	165,373	180,598
Holt-Winters aditivo	172,352	184,530
Naive estacional	207,322	219,664
SARIMA(2,1,2)×(1,0,1)$_{12}$	210,906	225,573
Respaldo aditivo*	239,791	252,070



Prueba abr 2021–jun 2026. Eje limitado a 650 mil; el intervalo continúa hasta 10.63 millones en jun 2026.

* Modelo aditivo de respaldo del Lab 1, no Prophet oficial. Entrenamiento: ene 2009–mar 2021. El intervalo amplio no garantiza utilidad.

04 Qué puede hacer INGUAT con esta evidencia

1 Preparar capacidad para diciembre (+35%) y probar campañas en febrero y septiembre, los meses más bajos.

2 Segmentar por región y frontera: Europa sufrió −94.1%; Valle Nuevo, −96.3%. Validar la demanda actual antes de asignar presupuesto.

3 Reentrenar con datos recientes y validar por ventanas móviles; el corte en pandemia deja pronósticos persistentemente bajos.

Fuente: Base de Migración 2009–jun 2026 INGUAT/IGM, facilitada en el curso. Serie: Turista + Excursionista; sin Crucerista ni Viajero.
Uso académico. Créditos: Ihan Marroquin 23108 y Diego Patzan 23525 · UVG · Data Science · Laboratorio 9.